DDRI 정본 데이터 공선성 위반 피처 제거 후보

대상: `ddri_prediction_canonical_train_2023_2024.csv`
타겟: `bike_change_raw`
분석일: 2025-03

---

1. 개요

원천데이터에서 `bike_change_raw`를 타겟으로 예측 시, 나머지 피처들 간 **공선성(다중공선성)** 위반 피처를 식별하고 제거 후보를 정리한 문서이다.

---

2. VIF (Variance Inflation Factor) 분석 결과

순위	피처	VIF	비고
1	rental_count	8.2e+14	rental_count_deseasonalized + seasonal_mean_2023와 완전 공선
2	rental_count_deseasonalized	8.2e+14	rental_count - seasonal_mean_2023로 정의됨
3	seasonal_mean_2023	8.3e+13	위 두 피처와 선형 관계
4	bike_change_trend_1_24	7,195	bike_change_lag_1 - bike_change_lag_24로 정의됨
5	bike_change_lag_24	3,931	bike_change_lag_1, bike_change_trend_1_24와 공선
6	bike_change_lag_1	3,652	위와 동일
7	bike_change_trend_24_168	506	bike_change_lag_24 - bike_change_lag_168로 정의됨
8	bike_change_lag_168	280	위와 동일
9	mapped_dong_code	41	cluster 등과 다중공선성 가능성
10	bike_change_deseasonalized	4.3	경미
11~	bike_change_rollstd_168, rollmean_24, rollstd_24, rollmean_168	2.5~2.7	양호
-	hour, humidity, temperature, wind_speed, precipitation, month, cluster, holiday, weekday	< 1.4	양호

기준: VIF > 10 → 공선성 위반, VIF > 5 → 주의

---

3. 상관계수 기반 고상관 쌍 (|r| > 0.7)

피처 A	피처 B	상관계수
rental_count	rental_count_deseasonalized	0.948
bike_change_rollstd_24	bike_change_rollstd_168	0.739
bike_change_lag_1	bike_change_trend_1_24	0.703
bike_change_lag_24	bike_change_trend_1_24	-0.703
bike_change_lag_168	bike_change_trend_24_168	-0.676
bike_change_lag_24	bike_change_trend_24_168	0.675

---

4. 제거 후보 리스트 (우선순위)

4.1 최우선 제거 (VIF > 100)

피처	사유
`rental_count_deseasonalized`	rental_count - seasonal_mean_2023로 정의, 완전 공선
`seasonal_mean_2023`	rental_count, rental_count_deseasonalized와 선형결합
`bike_change_trend_1_24`	bike_change_lag_1 - bike_change_lag_24 (lag 2개로 완전 설명)
`bike_change_trend_24_168`	bike_change_lag_24 - bike_change_lag_168 (lag 2개로 완전 설명)

4.2 권장 제거 (VIF > 5)

피처	사유
`mapped_dong_code`	VIF 41, cluster와 역할 중복 가능

4.3 선택적 제거 (lag 그룹 내 1~2개 축소 검토)

피처	사유
`bike_change_lag_24`	lag_1, lag_168, trend 파생과 공선
`bike_change_lag_168`	lag_24, trend 파생과 공선

※ `bike_change_lag_1`은 단기 패턴에 중요하므로 유지 권장

---

5. 권장 제거 조합 (최소 제거안)

```
# 공선성 위반 제거 후보 (bike_change_raw 타겟 기준)
REMOVE_CANDIDATES = [
    "rental_count_deseasonalized",  # rental_count, seasonal_mean_2023와 완
전 공선
```

```
    "bike_change_trend_1_24",        # lag_1, lag_24의 선형결합
    "bike_change_trend_24_168",     # lag_24, lag_168의 선형결합
    "mapped_dong_code",              # VIF 41, cluster와 역할 유사
]
```

유지 권장: `rental_count`(원천), `seasonal_mean_2023`(시간패턴), `bike_change_lag_1`, `bike_change_lag_24`, `bike_change_lag_168`(시차 정보)

---

6. 피처 정의식 (공선성 근거)

피처	정의식
rental_count_deseasonalized	rental_count - seasonal_mean_2023
bike_change_trend_1_24	bike_change_lag_1 - bike_change_lag_24
bike_change_trend_24_168	bike_change_lag_24 - bike_change_lag_168

---

7. 참고

- **분석 샘플**: train 100,000행
- **VIF 기준**: statsmodels `variance_inflation_factor`
- **상관 기준**: |r| > 0.7 고상관 쌍