Ridge 기반 End-to-End 분석 보고서

1. 분석 목적

- 목표는 `bike_change_raw`를 예측하는 해석 가능한 회귀모델을 만드는 것입니다.
- 발표에서는 `데이터 정제 -> 공선성 정리 -> 누수 점검 -> 시계열 패턴 진단 -> sample_weight 적용 -> Ridge 학습 -> 성능 검증` 순서로 설명합니다.

2. 데이터 구성

- 최종 입력 변수 수: **16개**
- 최종 예측 타깃: `bike_change_raw`

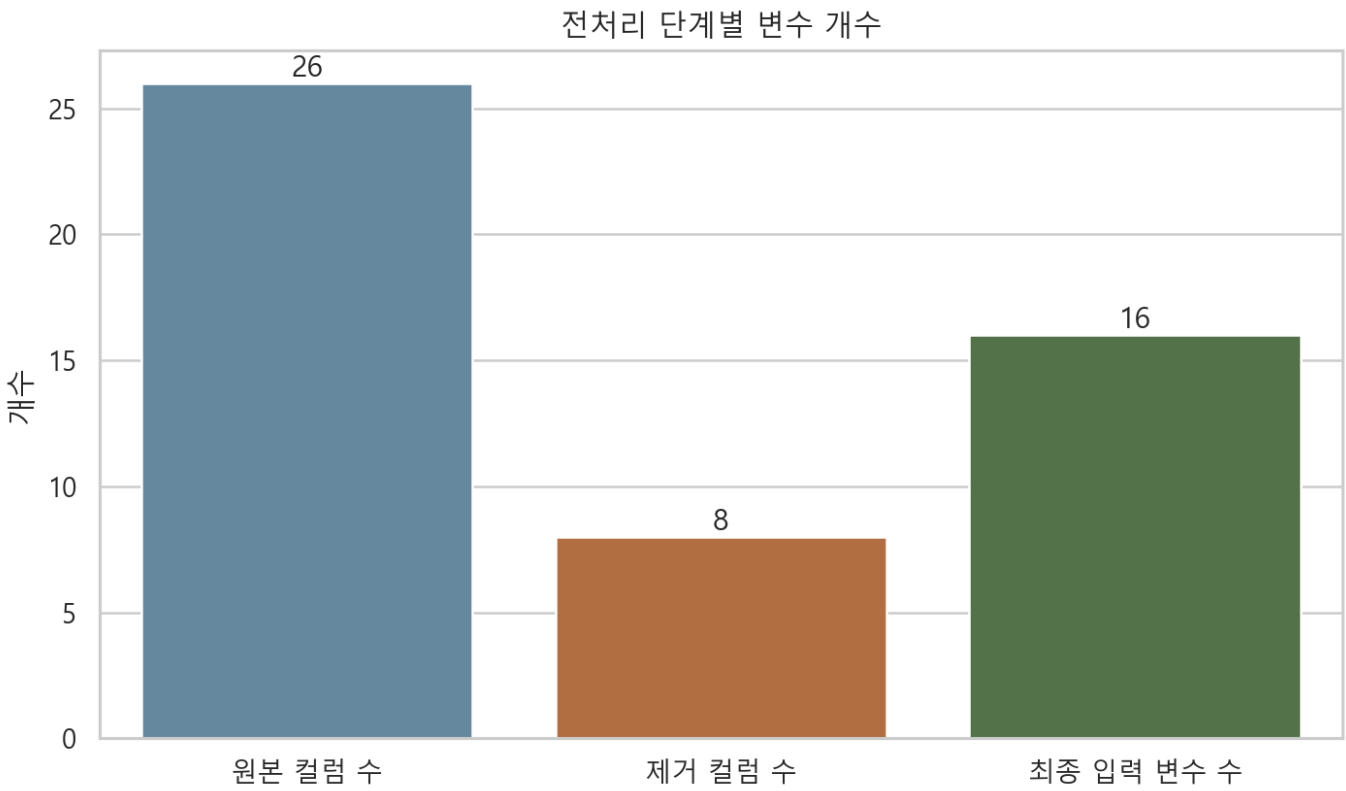

최종 컬럼 의미

컬럼	의미
station_id	대여소 고유 ID
hour	시간대(0~23시)

컬럼	의미
rental_count	해당 시점 대여 건수
weekday	요일 정보(월~일 인코딩)
month	월 정보
holiday	공휴일 여부
temperature	기온
humidity	습도
precipitation	강수량
wind_speed	풍속
cluster	대여소 군집 번호
bike_change_raw	예측 대상인 자전거 수요 변화량
bike_change_lag_1	직전 시점의 bike_change_raw
bike_change_rollmean_24	직전 24시간 bike_change_raw 평균
bike_change_rollstd_24	직전 24시간 bike_change_raw 표준편차
bike_change_rollmean_168	직전 168시간 bike_change_raw 평균
bike_change_rollstd_168	직전 168시간 bike_change_raw 표준편차
sample_weight	월별 유사패턴을 반영해 학습 시 곱해준 행 가중치

3. 데이터 정제와 공선성 정리

3-1. 왜 정리가 필요했는가

- 초기 데이터에는 원 변수와 계절조정 변수, 여러 시차·추세 파생변수가 함께 있어 상관관계가 높은 조합이 존재했습니다.
- 상관이 너무 높은 변수들을 동시에 넣으면 회귀계수 해석이 흔들리고, 학습 안정성이 떨어질 수 있습니다.

3-2. 근거 시각화

- 초기 공선성 점검 결과, `bike_change_raw`와 `bike_change_deseasonalized`의 절대 상관계수는 **0.9349**로 0.9를 넘었습니다.
- 이 값은 사실상 같은 정보를 두 컬럼이 나눠 들고 있다는 뜻이라 판단했습니다.

feature_a	feature_b	correlation	abs_correlation
bike_change_raw	bike_change_deseasonalized	0.934864	0.934864

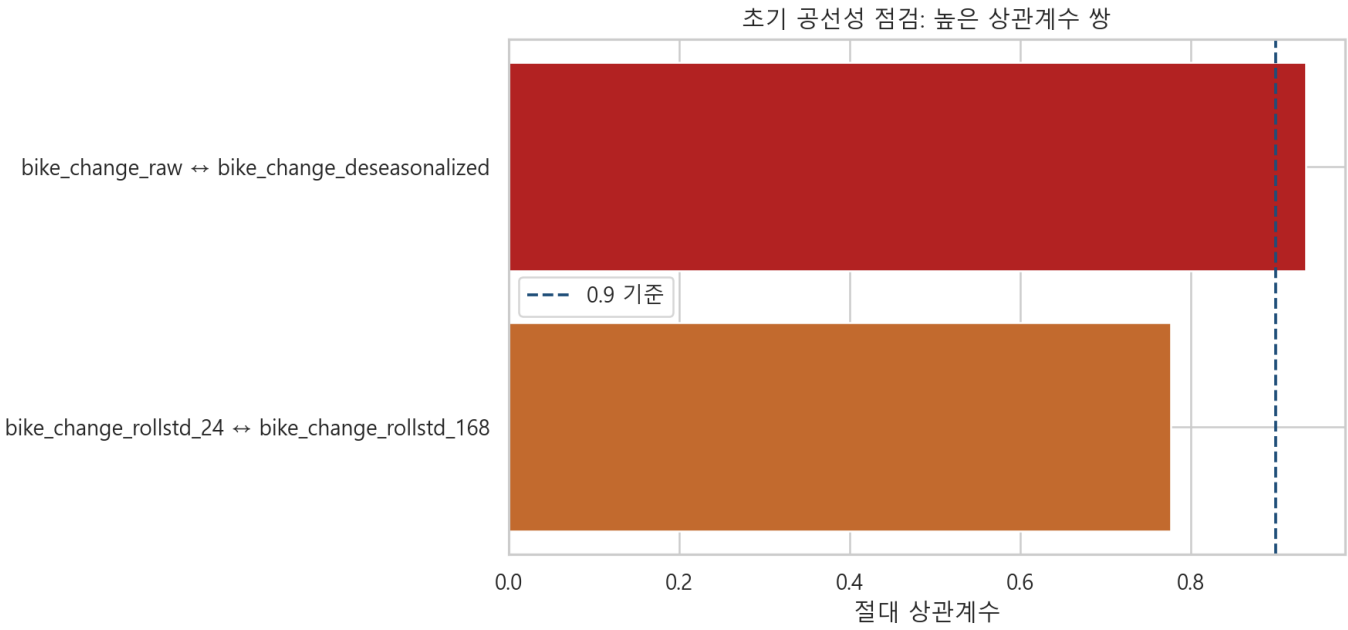

3-3. 어떤 조치를 했는가

제거 컬럼	원인	조치
bike_change_deseasonalized	bike_change_raw와 상관계수 0.9349로 매우 높음	중복 타깃 계열 변수 제거
rental_count_deseasonalized	원 변수와 계절조정 변수가 함께 존재	설명력이 겹치는 파생변수 제거
bike_change_trend_1_24 / bike_change_trend_24_168	bike_change 계열 추세 파생변수 중복	공선성 완화를 위해 제거
bike_change_lag_24 / bike_change_lag_168	다중 시차 변수 과다로 공선성 우려	대표 lag만 남기고 제거
seasonal_mean_2023	계절성 요약값이 월·시간 변수와 의미 중첩	대표성 낮은 요약 변수 제거
mapped_dong_code	지역 코드형 변수로 군집 변수와 역할 중첩	모델 단순화를 위해 제거

3-4. 조치 이후 결과

- 최종 입력 변수 기준 최대 절대 상관계수는 `bike_change_rollstd_24 ↔ bike_change_rollstd_168`의 **0.7772** 였습니다.
- 즉, 초기처럼 0.9를 넘는 강한 중복 구조는 최종 입력 변수에서는 남지 않았습니다.

feature_a	feature_b	correlation	abs_correlation
bike_change_rollstd_24	bike_change_rollstd_168	0.777213	0.777213
bike_change_rollmean_24	bike_change_rollmean_168	0.470136	0.470136
bike_change_lag_1	bike_change_rollmean_24	0.425102	0.425102
bike_change_lag_1	bike_change_rollmean_168	0.418752	0.418752
rental_count	bike_change_rollstd_168	0.355027	0.355027
rental_count	bike_change_rollstd_24	0.336581	0.336581

feature_a	feature_b	correlation	abs_correlation
temperature	bike_change_rollstd_168	0.307824	0.307824
temperature	bike_change_rollstd_24	0.261253	0.261253
hour	humidity	-0.257373	0.257373
humidity	wind_speed	-0.253358	0.253358

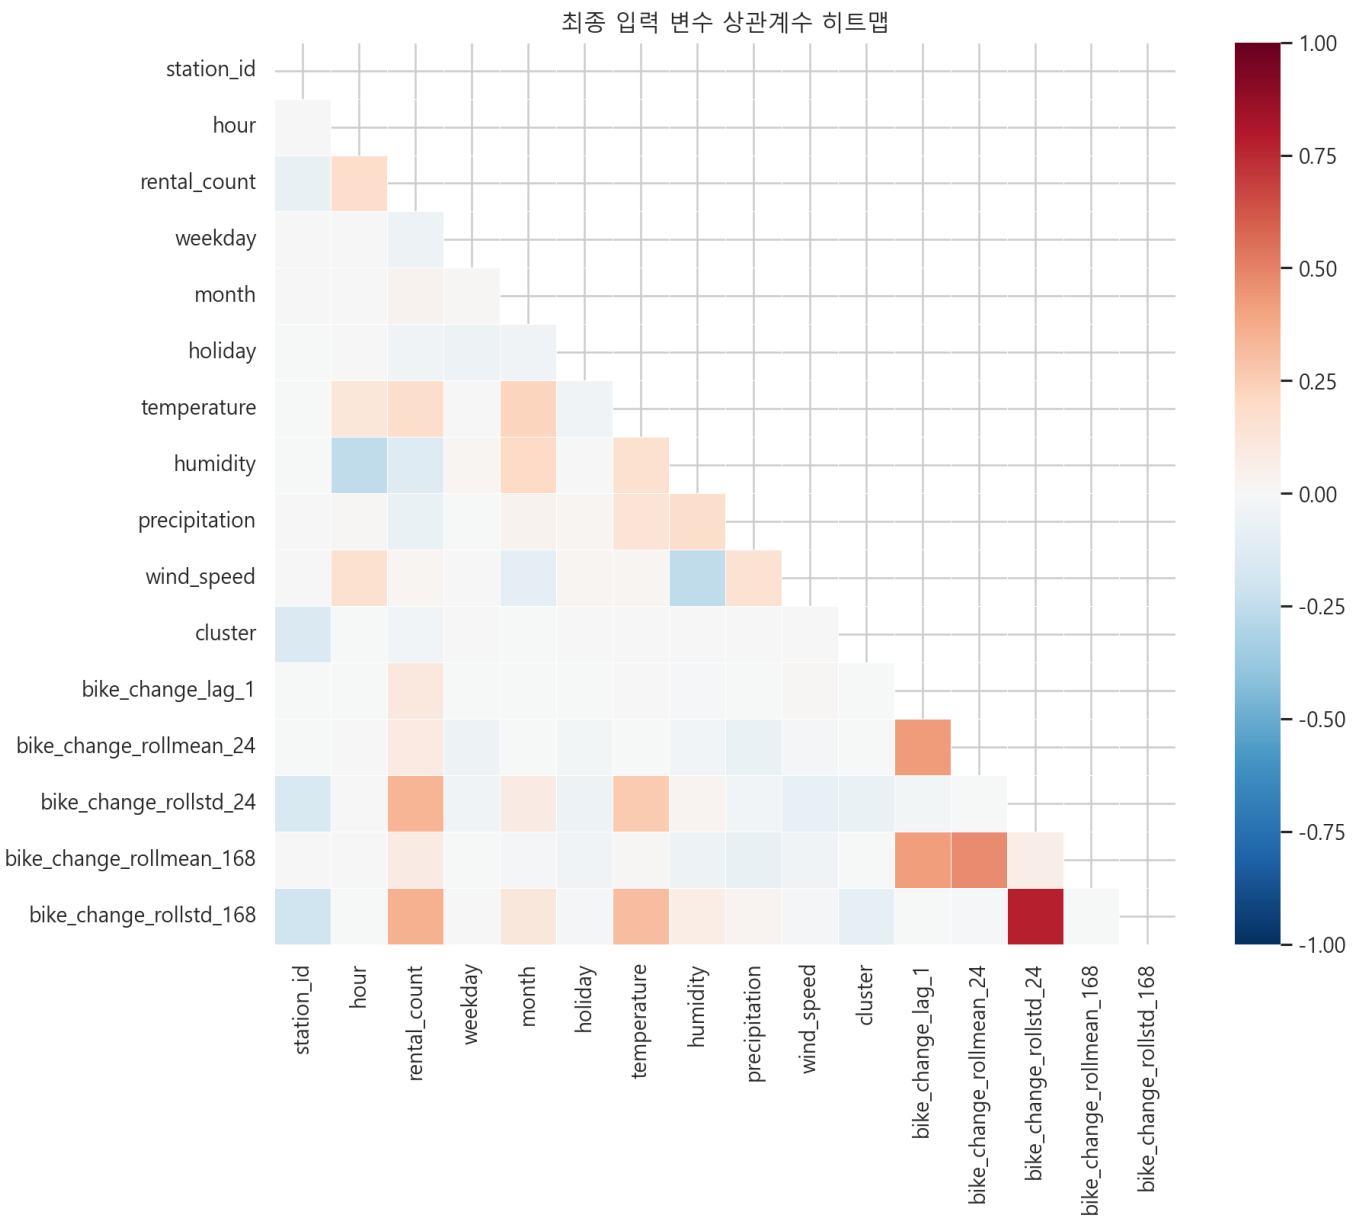

4. 누수와 분할 오류 점검

4-1. 무엇을 의심했는가

- 높은 성능이 나왔을 때 가장 먼저 의심해야 하는 것은 타깃 누수, 미래정보 혼입, 잘못된 train/valid/test 분할입니다.
- 특히 `bike_change_lag_1`, `bike_change_rollmean_24`, `bike_change_rollstd_24`, `bike_change_rollmean_168`, `bike_change_rollstd_168`는 타깃의 과거값에서 파생된 변수라 생성 로직을 확인할 필요가 있었습니다.

4-2. 점검 결과

- 과거값 기준 재계산 검증 결과, 위 5개 파생변수는 모두 **현재값이나 미래값을 쓰지 않고** 생성된 것으로 확인됐습니다.
- train/valid/test는 `2023 -> 2024 -> 2025` 시간순으로 분리되어 겹치지 않았습니다.

feature	mismatch_count_vs_past_only_formula	past_only_verified
bike_change_lag_1	0	True
bike_change_rollmean_24	0	True
bike_change_rollstd_24	0	True
bike_change_rollmean_168	0	True
bike_change_rollstd_168	0	True

split	min_date	max_date	rows
train	2023-01-01	2023-12-31	1410360
valid	2024-01-01	2024-12-31	1414224
test	2025-01-01	2025-12-31	1410360

left_split	right_split	overlap_key_rows
train	valid	0
train	test	0
valid	test	0

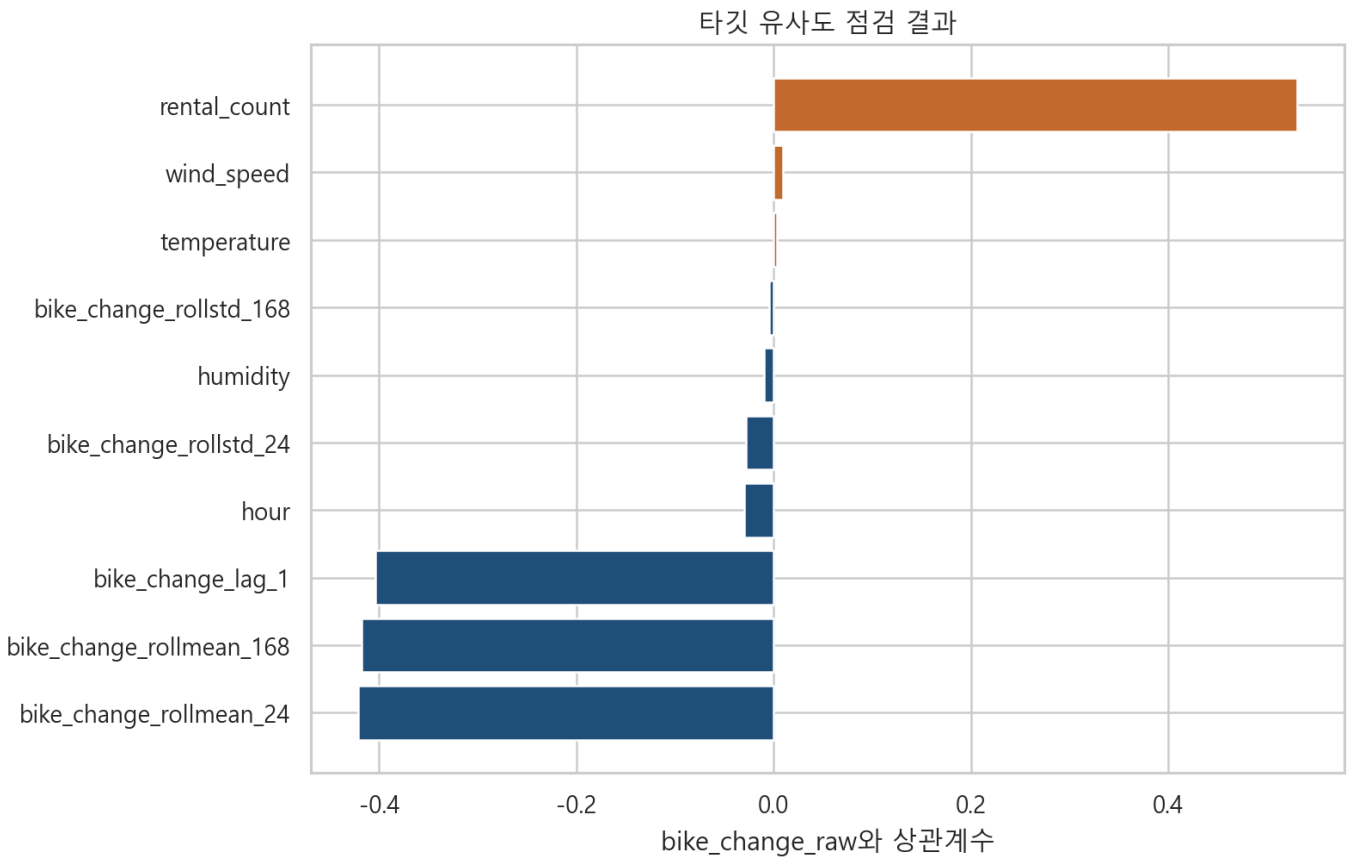

5. 시계열 패턴 진단과 sample_weight 설계

5-1. 왜 이 단계가 필요했는가

- 시계열 데이터에서는 누수는 없어도, 서로 너무 비슷한 월 패턴이 반복되면 특정 구간이 학습에 과도하게 반영될 수 있습니다.
- 그래서 인접한 월끼리 24시간 평균선을 비교해, 패턴이 매우 비슷한 달은 학습 가중치를 낮추는 전략을 적용했습니다.

5-2. 월별 유사패턴 근거

- `rental_count`의 `2023-05`와 `2023-06`은 `corr=0.9947`, `NRMSE=0.1074`로 매우 유사했습니다.
- 이런 형태는 일부 변수에서 반복적으로 관찰됐고, 이는 같은 패턴을 여러 달이 거의 중복해서 보여준다는 뜻입니다.

feature	year_month_left	year_month_right	corr	nrmse	similarity_score	similar_flag
weekday	2023-02	2023-03	1	0	1	True
rental_count	2023-05	2023-06	0.994728	0.107409	0.887885	True
humidity	2024-03	2024-04	0.995387	0.126415	0.869555	True
bike_change_lag_1	2024-05	2024-06	0.990595	0.136922	0.854961	True
rental_count	2023-12	2024-01	0.992545	0.153107	0.840579	True
rental_count	2024-05	2024-06	0.989127	0.155049	0.835763	True
rental_count	2024-04	2024-05	0.986511	0.164927	0.823809	True
rental_count	2024-07	2024-08	0.986366	0.17046	0.81823	True
bike_change_lag_1	2024-04	2024-05	0.985858	0.173726	0.814589	True
bike_change_lag_1	2024-01	2024-02	0.982876	0.187159	0.798923	True
rental_count	2023-07	2023-08	0.99599	0.198556	0.79823	True
bike_change_lag_1	2023-05	2023-06	0.984816	0.19737	0.790443	True

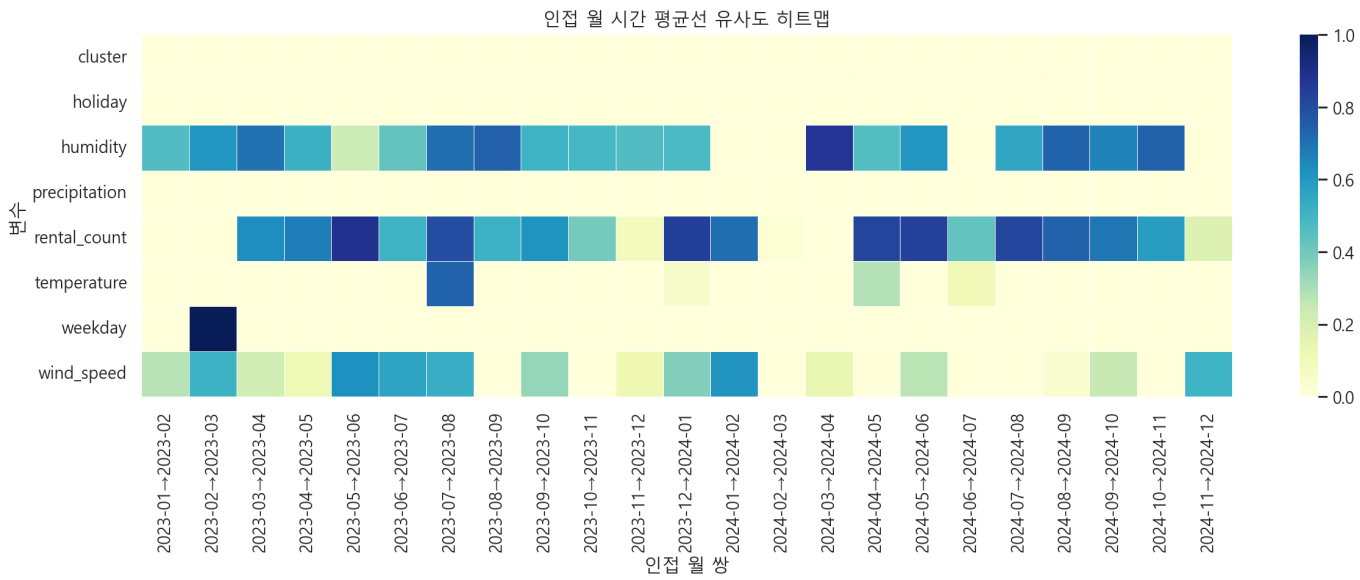

5-3. 월별·일별·시간별 패턴 시각화

- 아래 그림은 대표 예시로 `rental_count`의 두 인접 월을 비교한 것입니다.
- 월 수준에서는 두 달의 전체 가중치가 비슷하게 낮아지고, 일 수준에서는 요일별 평균 패턴이 유사하며, 시간 수준에서는 24시간 평균선의 모양이 거의 겹칩니다.

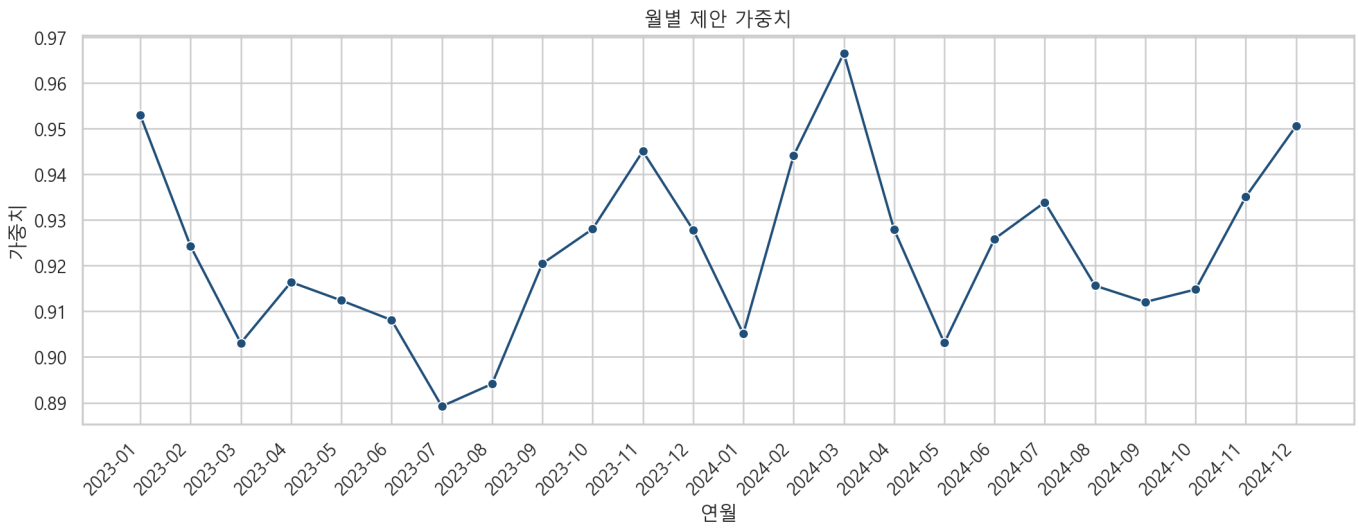
월별 제안 가중치
가중치
0.97
0.96
0.95
0.94
0.93
0.92
0.91
0.90
0.89
2023-01
2023-02
2023-03
2023-04
2023-05
2023-06
2023-07
2023-08
2023-09
2023-10
2023-11
2023-12
2024-01
2024-02
2024-03
2024-04
2024-05
2024-06
2024-07
2024-08
2024-09
2024-10
2024-11
2024-12
연월

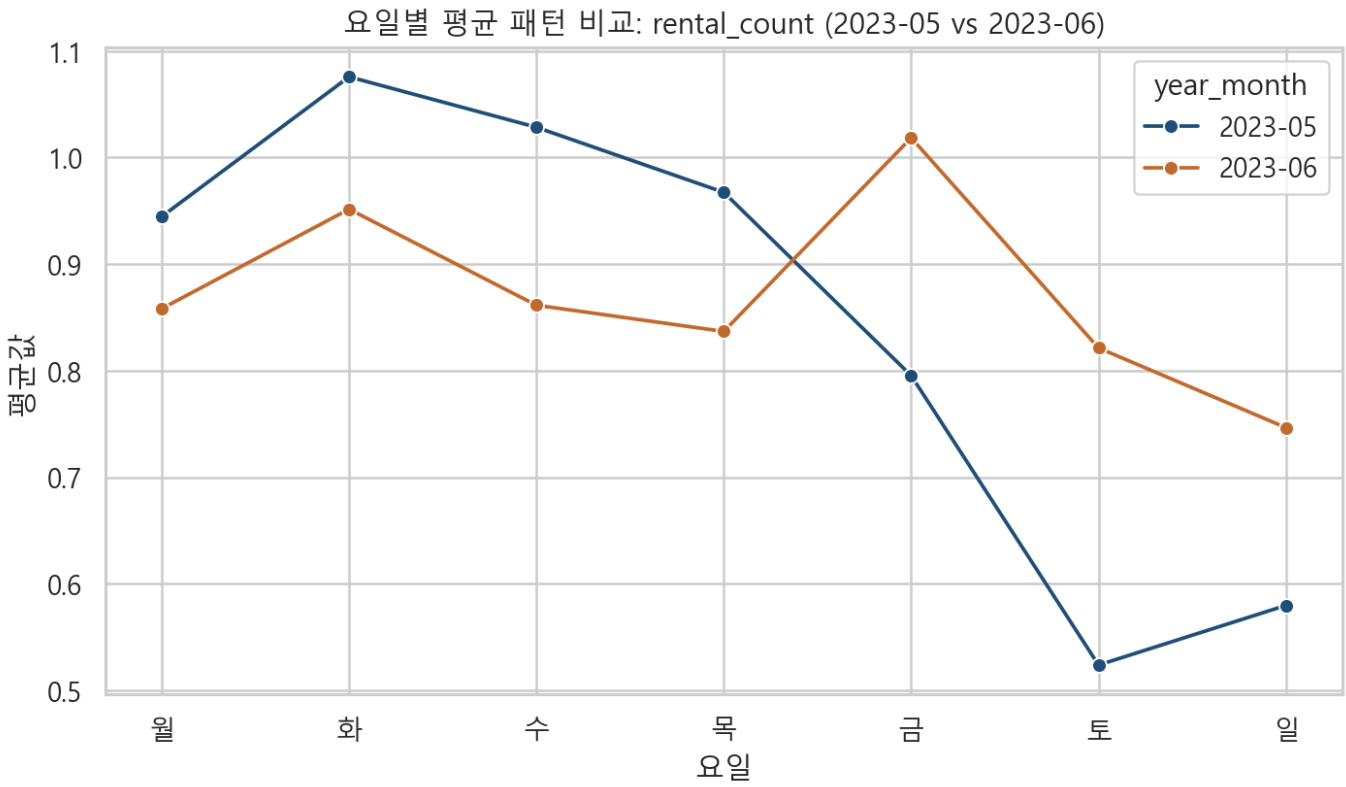
요일별 평균 패턴 비교: rental_count (2023-05 vs 2023-06)
평균값
1.1
1.0
0.9
0.8
0.7
0.6
0.5
year_month
2023-05
2023-06
월
화
수
목
금
토
일
요일

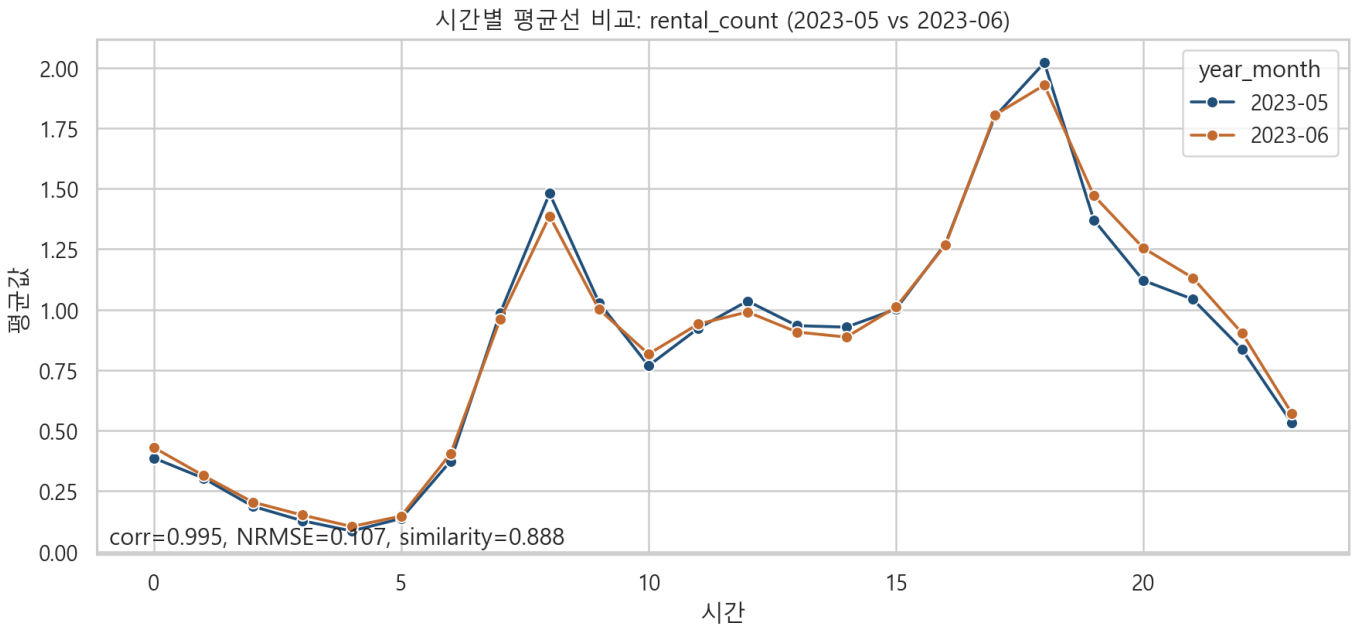

5-4. 어떤 조치를 했는가

- 각 월에 대해 `sample_weight`를 부여했고, 실제 범위는 **0.889208 ~ 0.966489**였습니다.
- 패턴 유사도가 높은 달일수록 가중치를 조금 낮춰서, 중복되는 계절·시간 패턴이 학습을 과하게 지배하지 않도록 했습니다.

year_month	overall_month_weight	mean_adjacent_similarity
2023-07	0.889208	0.221584
2023-08	0.894102	0.211796
2023-03	0.90306	0.19388
2024-05	0.903093	0.193813
2024-01	0.905062	0.189876

6. 데이터 분할과 모델링

6-1. 가중치 -> 선형회귀식 -> Ridge 적용 흐름

- 먼저 월별 반복패턴 분석 결과를 이용해 각 학습 행의 `sample_weight`를 계산했습니다.
- 다음으로 선형회귀식 형태(`y_hat = b0 + b1x1 + ... + bkxk`)로 타깃을 설명했습니다.
- 마지막으로 같은 선형식에 L2 규제를 더한 `Ridge`를 사용해, 다중공선성 상황에서도 계수가 과도하게 흔들리지 않게 학습했습니다.
- 즉, 이 보고서의 모델은 `가중치가 적용된 선형회귀식`을 기반으로 하고, 이를 Ridge 목적함수로 최적화한 구조입니다.

```
1) sample_weight 계산
2) 선형회귀식 설정: y_hat = b0 + b1x1 + ... + bkxk
3) Ridge 학습: min Σ w_i (y_i - y_hat_i)^2 + α Σ b_j^2
```

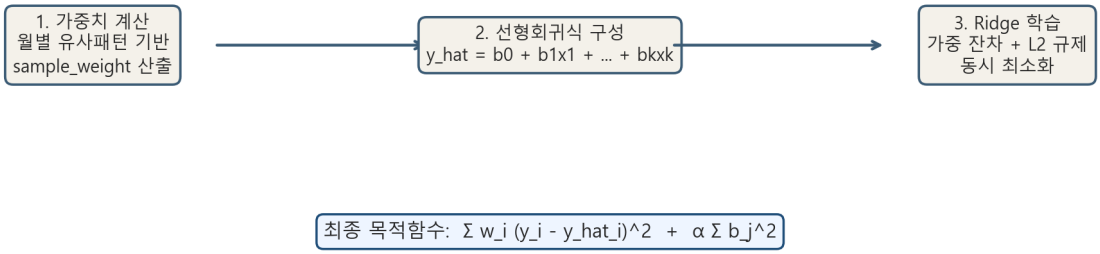

6-2. 실험 설정

- 분할 방식: `train=2023`, `valid=2024`, `test=2025`
- 모델: `Ridge(alpha=2.0)`
- 전처리: median imputation + standardization
- 학습 시 `sample_weight` 적용
- 평가 지표: `RMSE`, `MAE`, `R2`

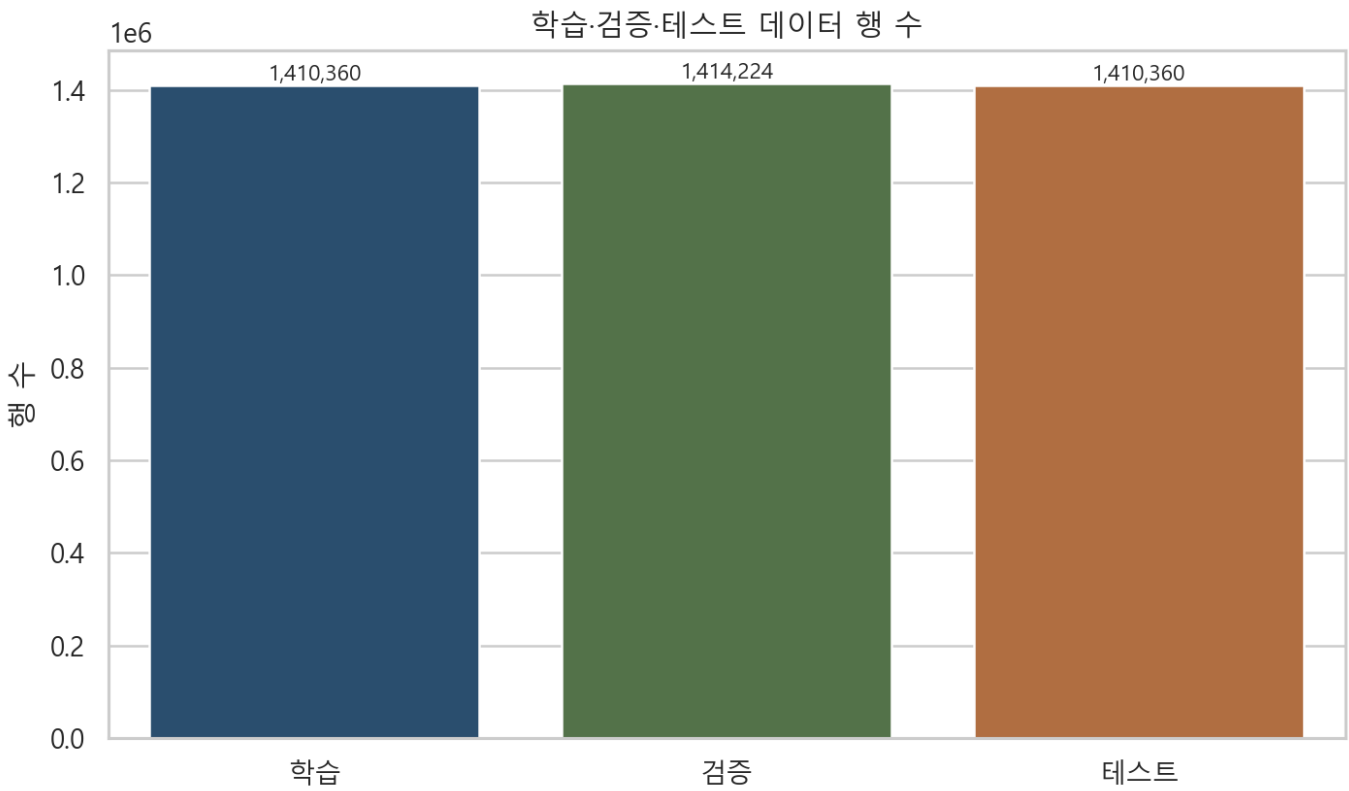

7. 전체 Ridge 회귀 성능

split	rmse	mae	r2
train	0.726203	0.481299	0.726576
valid	0.734183	0.480287	0.721155
test	0.649735	0.433503	0.727374

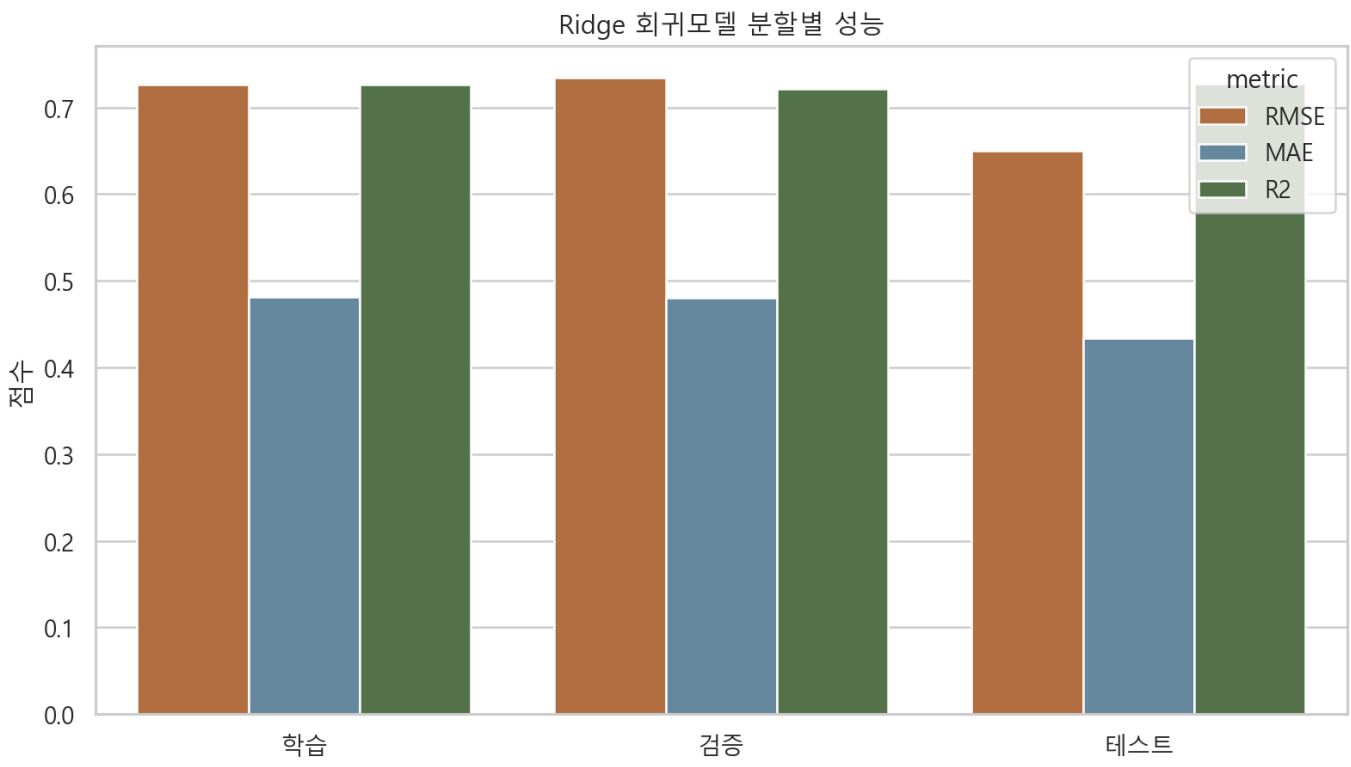

성능 해석

- train R2=0.726576, valid R2=0.721155, test R2=0.727374로 split 간 차이가 크지 않았습니다.
- 즉, Ridge는 과적합이 심하지 않으면서도 설명 가능한 수준의 안정적인 성능을 보였습니다.

8. 회귀계수 해석

- 표준화 계수 기준 상위 변수는 `rental_count`, `bike_change_lag_1`, `bike_change_rollmean_24`, `bike_change_rollmean_168` 순으로 영향이 컸습니다. | feature | standardized_coefficient | abs_standardized_coefficient | |:----------|----------😐----------😐 | rental_count | 1.04008 | 1.04008 | | bike_change_lag_1 | -0.381124 | 0.381124 | | bike_change_rollmean_24 | -0.369743 | 0.369743 | | bike_change_rollmean_168 | -0.319655 | 0.319655 | | bike_change_rollstd_168 | -0.218623 | 0.218623 | | hour | -0.214313 | 0.214313 | | bike_change_rollstd_24 | -0.201558 | 0.201558 | | humidity | 0.0571189 | 0.0571189 | | temperature | -0.0392703 | 0.0392703 | | weekday | 0.0225105 | 0.0225105 | | month | -0.0140298 | 0.0140298 | | precipitation | 0.0119273 | 0.0119273 |

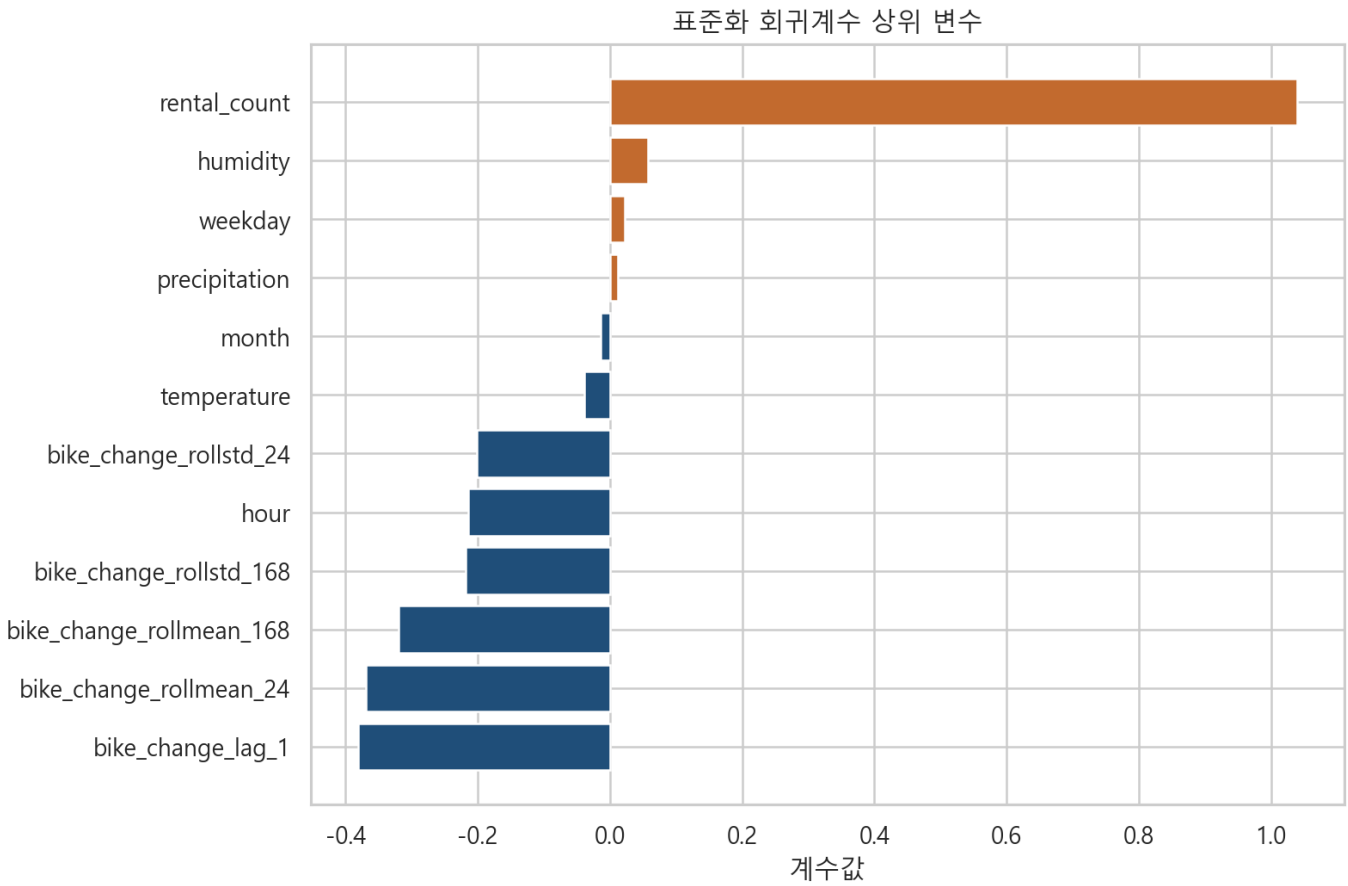

10. 클러스터별 Ridge 결과

cluster	split	rows	rmse	mae	r2
0	test	411720	0.674678	0.444958	0.716517
0	train	411673	0.707902	0.474743	0.727554
0	valid	412848	0.722132	0.476679	0.721616
1	test	26280	1.28032	0.833222	0.597371
1	train	26277	1.42566	0.906979	0.627466
1	valid	26352	1.55819	0.942779	0.57663
2	test	271560	0.743986	0.500475	0.709224
2	train	271529	0.84883	0.561895	0.708962
2	valid	272304	0.860342	0.569328	0.706416
3	test	534360	0.55388	0.394516	0.769746
3	train	534299	0.644872	0.447759	0.759563
3	valid	535824	0.623939	0.435514	0.763951
4	test	166440	0.495616	0.342718	0.781277
4	train	166421	0.567856	0.377508	0.759377
4	valid	166896	0.590129	0.383617	0.756883

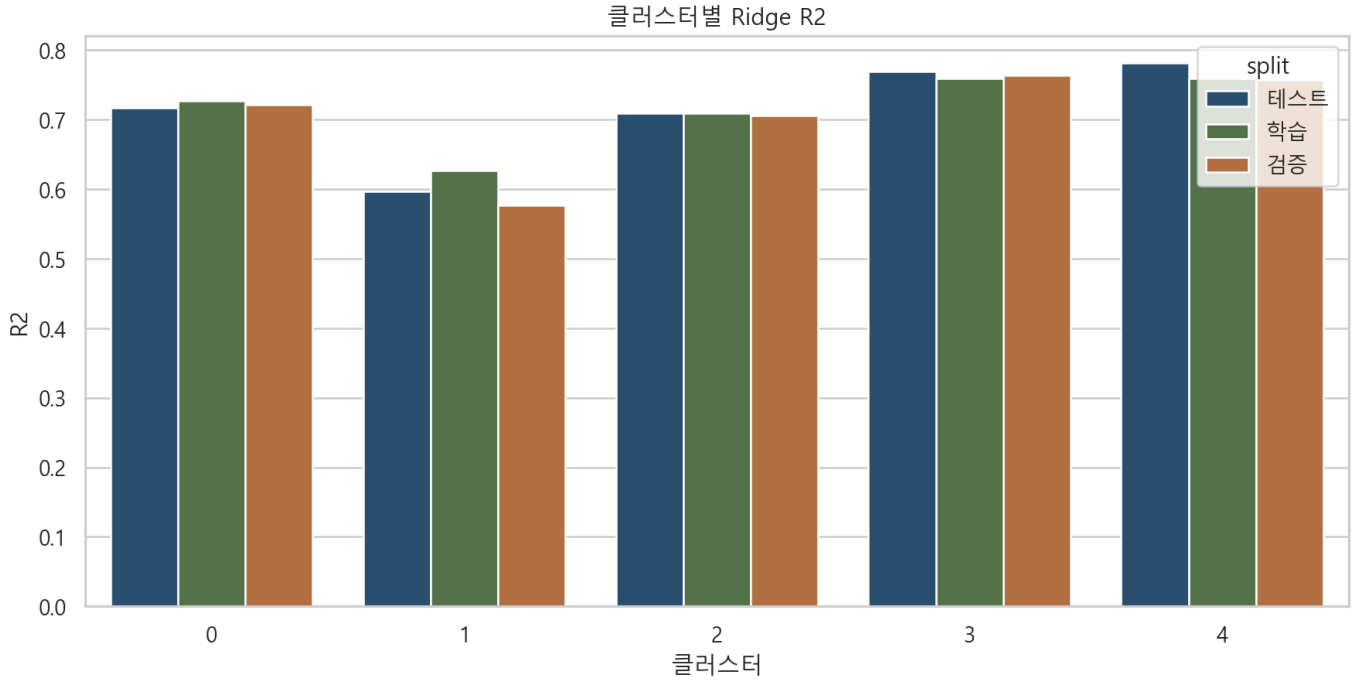

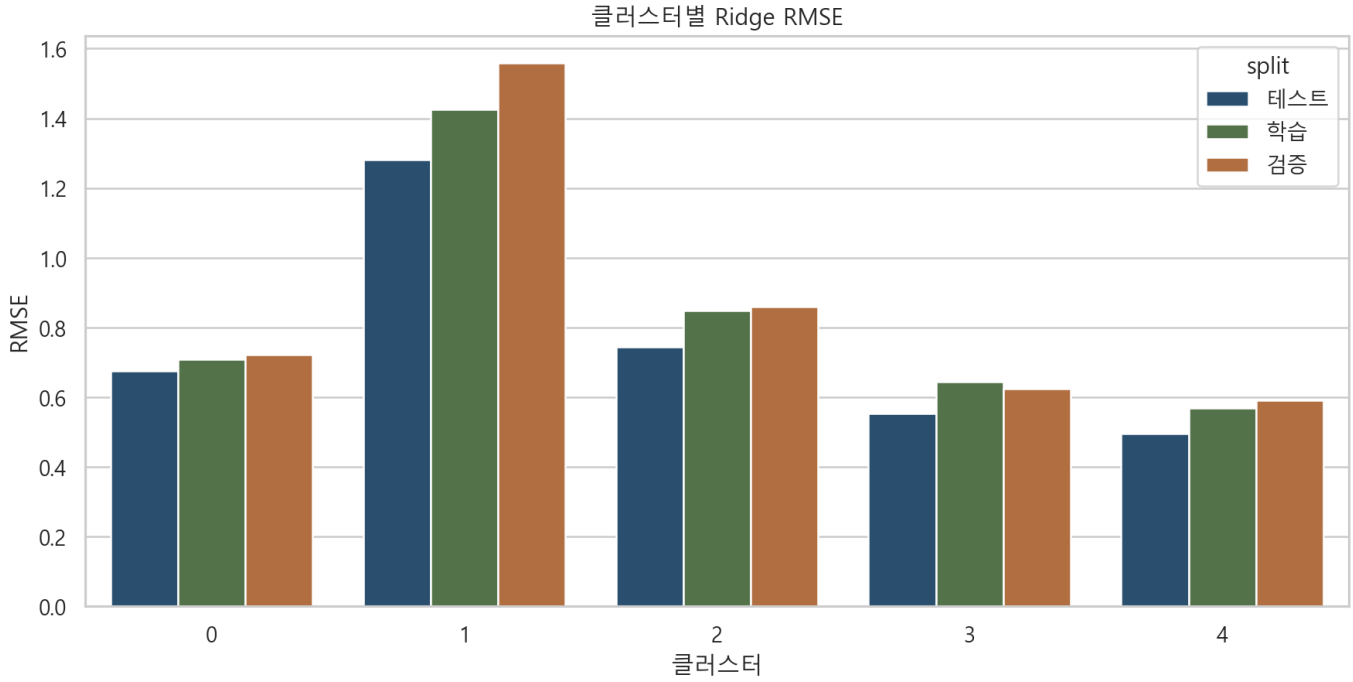

- 검증 기준 최고 클러스터는 `cluster 3`로 R2=0.763951였습니다.
- 테스트 기준 최고 클러스터는 `cluster 4`로 R2=0.781277였습니다.
- `cluster 1`은 상대적으로 성능이 낮아 군집 특화 feature 보강이 필요한 구간으로 보입니다.

11. 결론

- 공선성 정리 단계에서는 고상관 변수와 중복 파생변수를 제거해 해석 가능한 회귀 구조를 확보했습니다.
- 누수 점검 단계에서는 미래정보 혼입과 잘못된 분할이 없음을 확인했습니다.
- 시계열 패턴 진단 단계에서는 월별·요일별·시간별 유사패턴이 반복되는 것을 확인했고, 이를 완화하기 위해 `sample_weight`를 적용했습니다.
- 그 결과 Ridge는 `R2 약 0.72` 수준의 안정적이고 설명 가능한 기준 모델로 정리할 수 있었습니다.