통합 군집화 레포트 초안

1. 왜 통합 군집화가 필요했는가

1차 군집화는 평균 대여량, 평일/주말 평균, 출퇴근 비율 등 수요 규모 중심 피처로 구성되어 있었다. 그 결과 일반수요형과 고수요형의 분리는 가능했지만, 원래 목표였던 업무지구, 주거지구, 상권, 복합 거점 같은 공간적 성격을 설명하는 데는 한계가 있었다.

따라서 이번 통합 군집화는 다음 두 축을 결합했다.

- 반납 시간대 기반 지구판단 피처
- 교통 접근성과 순유입 정보

이렇게 해서 군집을 단순 이용량이 아니라 도착 수요의 공간적 역할 기준으로 다시 해석한다.

2. 최종 입력 피처

군집화 핵심 입력 7개:

- `arrival_7_10_ratio` : 07~10시 반납 비율
- `arrival_11_14_ratio` : 11~14시 반납 비율
- `arrival_17_20_ratio` : 17~20시 반납 비율
- `morning_net_inflow` : 아침 순유입
- `evening_net_inflow` : 저녁 순유입
- `subway_distance_m` : 최근접 지하철 거리
- `bus_stop_count_300m` : 300m 내 버스정류장 수

보조 해석 컬럼:

- `total_return_count`
- `return_7_10_count`
- `return_11_14_count`
- `return_17_20_count`
- `dominant_ratio`
- `district_hypothesis`
- `life_pop_*`

메인 피처 해석 원칙:

- 반납 시간대 3개는 언제 해당 대여소로 사람이 모이는가를 본다.
- 순유입 2개는 언제 자전거가 실제로 들어오고 빠져나가는가를 본다.
- 교통 접근성 2개는 지하철/버스 접근이 좋은 중심축인지를 본다.

3. 군집 수 탐색

탐색 범위는 `k = 5 ~ 7`로 두었다.

k	inertia	silhouette

k	inertia	silhouette
5	542.47	0.2033
6	498.33	0.1795
7	465.91	0.1708

선택 결과:

- 최종 선택 `k = 5`
- 이유: 탐색 범위 내 silhouette가 가장 높음

주의:

- silhouette 값은 1차보다 낮다.
- 하지만 이번 군집화는 `분리도 최적화`보다 `지구판단 해석력 확보`를 우선한 설계다.

4. 군집별 요약

군집	station 수	07-10 비율	11-14 비율	17-20 비율	아침 순유입	저녁 순유입	지하철 거리	해석 초안
0	49	0.283	0.187	0.233	1162.9	-792.3	472.1m	업무/상업 혼합형
1	3	0.486	0.160	0.161	10421.0	-4702.0	435.7m	아침 도착 업무 집중형
2	32	0.113	0.150	0.383	-2016.7	1215.0	390.5m	주거 도착형
3	61	0.153	0.198	0.307	-489.2	20.6	282.7m	생활·상권 혼합형
4	19	0.157	0.159	0.312	-842.9	477.4	1616.6m	외곽 주거형

5. 군집 라벨 후보

Cluster 0: 업무/상업 혼합형

- 아침 도착 비율이 높고, 점심 비율도 완전히 낮지 않음
- 아침 순유입이 플러스, 저녁 순유입은 마이너스
- 대표 지점:
  - `SB타워 앞`
  - `역삼지하보도 7번출구 앞`
  - `구역삼세무서 교차로`

Cluster 1: 아침 도착 업무 집중형

- 아침 도착 비율이 압도적으로 높음
- 아침 순유입 규모가 매우 큼
- station 수는 적지만 성격이 매우 분명함
- 대표 지점:
  - `수서역 5번출구`

    - 주식회사 오뚜기 정문 앞
    - 포스코사거리(기업은행)

Cluster 2: 주거 도착형

- 저녁 도착 비율이 가장 높음
- 아침 순유출, 저녁 순유입 구조가 명확함
- 대표 지점:
    - 청담역 13번 출구 앞
    - 청담역 2번출구
    - 현대아파트 정문 앞

Cluster 3: 생활·상권 혼합형

- 저녁 도착이 우세하지만 점심 비율도 비교적 높음
- 지하철 접근성이 좋고 생활권 중심역 주변이 많음
- 대표 지점:
    - 학여울역 사거리
    - 도곡역 대치지구대 방향
    - 대치역 7번출구

Cluster 4: 외곽 주거형

- 저녁 도착형이지만 지하철 접근성이 크게 떨어짐
- 외곽/주거 생활권 성격이 상대적으로 강함
- 대표 지점:
    - 더시그넘하우스 앞
    - 국립국악중,고교 정문 맞은편
    - 세곡동 사거리

6. 발표에 쓸 핵심 근거

차트:

- `images/ddri_second_kmeans_elbow_silhouette.png`
- `images/ddri_second_kmeans_pca_scatter.png`
- `images/ddri_second_cluster_feature_means.png`
- `images/ddri_second_cluster_profile_heatmap.png`
- `images/ddri_second_cluster_size.png`
- `images/ddri_second_cluster_hypothesis_crosstab.png`

지도:

- `../return_time_district/ddri_return_map_2025_7_10.html`
- `../return_time_district/ddri_return_map_2025_11_14.html`
- `../return_time_district/ddri_return_map_2025_17_20.html`
- `ddri_second_cluster_map.html`

표:

- `data/ddri_second_cluster_summary.csv`
- `data/ddri_second_cluster_representative_stations.csv`
- `data/ddri_second_cluster_hypothesis_crosstab.csv`

7. POI 보강 실험 결과

상권 해석을 더 직접적으로 보강하기 위해 서울시 사업장 인허가 원천에서 오프라인 상권/생활편의 POI를 별도 가공해 군집화 비교 실험을 수행했다.

공식 원천:

- `지방행정 인허가 데이터개방`
- https://www.localdata.go.kr/devcenter/dataDown.do?menuNo=20001

POI 보강 실험에 실제 사용한 피처:

- `log1p_restaurant_count_300m` : log1p(300m 내 일반음식점 수)
- `log1p_cafe_count_300m` : log1p(300m 내 커피숍 수)
- `log1p_convenience_store_count_300m` : log1p(300m 내 편의점 수)
- `log1p_pharmacy_count_300m` : log1p(300m 내 약국 수)
- `log1p_food_retail_count_1000m` : log1p(1000m 내 식품판매업(기타) 수)
- `log1p_fitness_count_500m` : log1p(500m 내 체력단련장 수)
- `log1p_cinema_count_1000m` : log1p(1000m 내 영화상영관 수)

후보로 검토했지만 최종 적용에서 제외한 피처:

- `golf_practice_count_1000m` : 골프연습장 수, 따릉이 목적지 직접성이 낮아 제외
- `bakery_count_300m` : 제과점 수, 카페와 중복이 커 제외
- `hospital_count_500m` : 병원 수, 후보로 실험했으나 silhouette를 더 낮춰 제외
- `통신판매업` 계열: 온라인 판매 성격이 강해 오프라인 상권 피처로 부적절

실험 결과:

실험	k	최고 silhouette
메인 통합 군집화	5	0.2033
POI 보강 실험	5	0.1576

판단:

- `restaurant`와 `food_retail`을 포함하면 상권 밀집도 설명은 더 자연스러워진다.
- 그러나 현재는 시간대/순유입/교통 접근성 중심 메인 피처보다 분리도가 낮다.
- 즉 POI 피처는 `후반 실험 결과`와 `상권 해석 보조 근거`로는 유효하지만, 이번 단계에서 메인 군집화 피처로 채택할 수준은 아니었다.

8. 이후 예측 모델로의 연결

이 군집화의 목적은 군집 자체가 아니라 이후 `station-day 수요 예측`으로 연결되는 것이다.

군집을 통해 다음과 같이 후속 피처를 더 선별할 수 있다.

- 업무/상업 혼합형:
  - 평일/공휴일
  - 아침 생활인구
  - 출근 시간 강수와 기온
- 주거 도착형:
  - 저녁 강수
  - 주말 여부
  - 귀가 시간대 체감기온
- 생활·상권 혼합형:
  - 점심 생활인구
  - 점심 시간 강수/기온
  - 교통 접근성
- 외곽 주거형:
  - 고저차
  - 버스 접근성
  - 장거리 이동 부담 변수

최종 예측 평가는 아래 지표로 진행한다.

- `RMSE`
- `MAE`
- R^2