강남구 따릉이 Station별 대여량 예측 프로젝트

발표 범위

- 기준 문서: `ddareungi_demand_project_canvas.md`
- 현재 진행 기준일: `2026-03-12`
- 공간 범위: 강남구
- 학습 기간: `2023~2024`
- 테스트 기간: `2025`

현재 발표 목적

- 프로젝트 목표와 문제 정의를 캔버스 순서대로 정리
- 현재까지 완료한 분석/데이터셋 구축 결과 공유
- 군집화 성과와 예측 모델 준비 상태를 중간 점검

> **현재 발표 단계 = 기준 정의 확정 + 1차 분석 기반 공유**

1. 프로젝트 목적

프로젝트 목표

- 강남구 Station별 하루 따릉이 대여량 예측
- 시간, 날씨, 공휴일, 주변 환경, 과거 수요를 함께 반영
- 예측 결과를 웹 지도 기반 서비스로 연결

현재까지 확정한 방향

- 1차 예측 target: `Station별 하루 대여량`
- 운영 해석 지표: `적정 보유 대수`는 예측 이후 해석 단계로 분리
- 웹 출력은 추후 Flutter 기반 지도 시각화와 연계 예정

2. 문제 정의

목표 문제

- 문제 유형: 회귀
- target: `rental_count`
- grain: `station_id + date`

왜 일 단위 예측인가

- 내부 기획 문서와 웹 조회 흐름이 날짜 기준 조회와 가장 잘 맞음
- 현재 데이터 구조상 시간 단위보다 일 단위가 더 안정적
- 1차 baseline 구축과 해석에 적합

> **1차 target = Station별 하루 대여량, 적정 보유 대수 = 2차 운영 해석 지표**

3. 데이터 구성

내부 데이터

- 강남구 따릉이 이용 이력
- 강남구 대여소 마스터
- target 생성용 station-day 집계 테이블

외부 데이터

- 날씨: Open-Meteo 및 기존 수집 자료
- 공휴일: 한국천문연구원 특일 정보 API
- 환경: 공원, 지하철, 버스정류장 위치 정보

현재 확보 산출물

- 학습 target: `ddri_station_day_target_train_2023_2024.csv`
- 테스트 target: `ddri_station_day_target_test_2025.csv`
- 학습/테스트 베이스라인: `ddri_station_day_train_baseline_dataset.csv`, `ddri_station_day_test_baseline_dataset.csv`

4. 데이터 전처리

전처리 기준

- 결측치 제거
- `이용시간(분) <= 0` 제거
- `이용거리(M) <= 0` 제거
- `동일 대여소 반납`이면서 `이용시간(분) <= 5` 제거
- 공통 기준 밖 대여소 제거
- 강남구 기준 밖 반납 대여소 제거
- 그 외 동일 대여소 반납은 제거하지 않고 유지

추가 점검

- 원천 중복 로그 점검 완료
- feature 극단치 후보 점검 완료
- 극단치는 1차 군집화에서 임의 제거하지 않고 유지

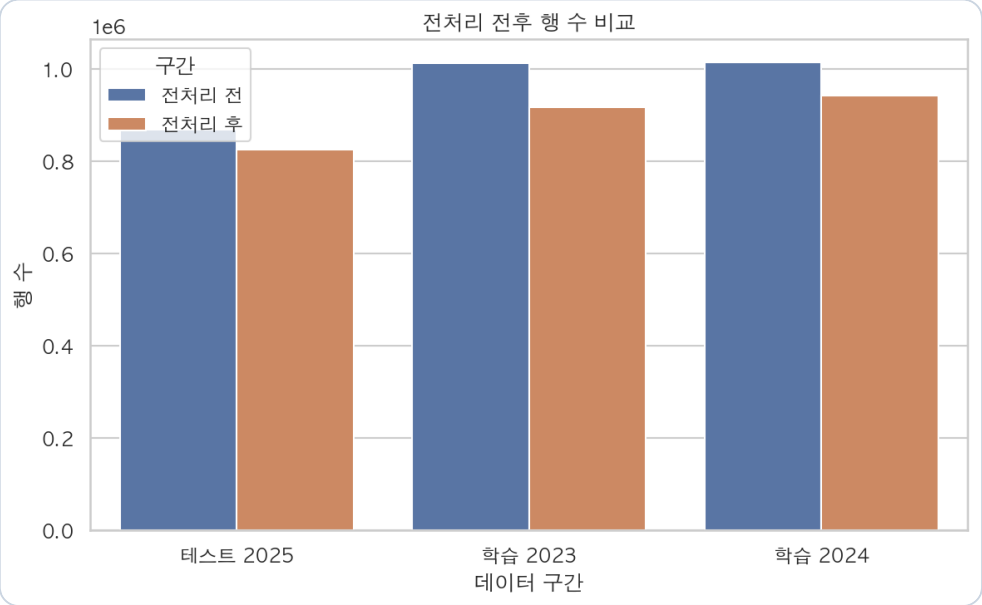

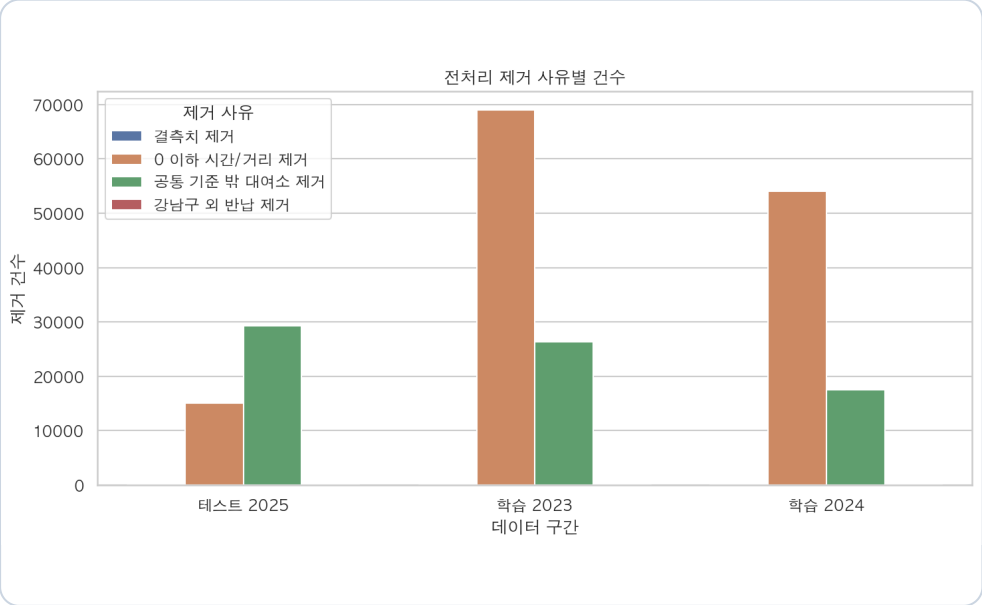

- 전처리 영향은 비정상 시간·거리 값과 기준 밖 대여소 제거가 가장 큼
- 없는 값은 임의 보간하지 않고, 기준에 따라 제거 또는 보류
- 같은 대여소로 5분 이내 반납된 건은 제거하고, 그 외 기록은 재고 변동성 해석용 지표 후보로 유지

5. 탐색적 데이터 분석 (EDA)

현재 진행 상태

- 대여소별 평균 대여량 패턴 점검
- 군집화용 요약 feature 생성
- 대여소 분포와 수요 규모 차이 확인

1차 EDA 핵심 결과

- 강남구 대여소는 수요 규모 차이가 뚜렷함
- 일부 대여소는 평균 대여량과 변동성이 모두 높음
- 단순 평균 비교만으로도 유형화 필요성이 확인됨

> **EDA 1차 완료, 군집화와 feature 설계 근거 확보**

6. Feature Engineering 및 도입 근거

현재 확정한 feature 그룹

- 시간 feature
- 날씨 feature
- 공휴일 feature
- 과거 수요 feature
- 정적 환경 feature
- 군집 label

현재 반영 완료 항목

- 날씨: 일 단위 집계 완료
- 공휴일: API 수집 및 일 단위 캘린더 생성 완료
- 환경: 공원 거리, 지하철 거리, 버스정류장 수 반영 완료
- 군집 label: 고수요형/일반수요형 반영 가능
- 운영 보조 지표: self-return 비율, 반납량, 순유출입(net flow) 생성 완료

운영 해석용 추가 지표

- `return_count`
- `same_station_return_count`
- `same_station_return_ratio`
- `net_flow`

- 학습 데이터 기준 self-return 비율 평균: `8.49%`
- 테스트 데이터 기준 self-return 비율 평균: `9.12%`
- 같은 대여소 5분 이내 반납은 제거하고, 그 외 기록은 재고 변동성 해석용 보조 지표로 유지
- 즉 실제 수요와 재고 변동을 분리해서 보기 위한 운영 해석용 feature를 추가한 상태

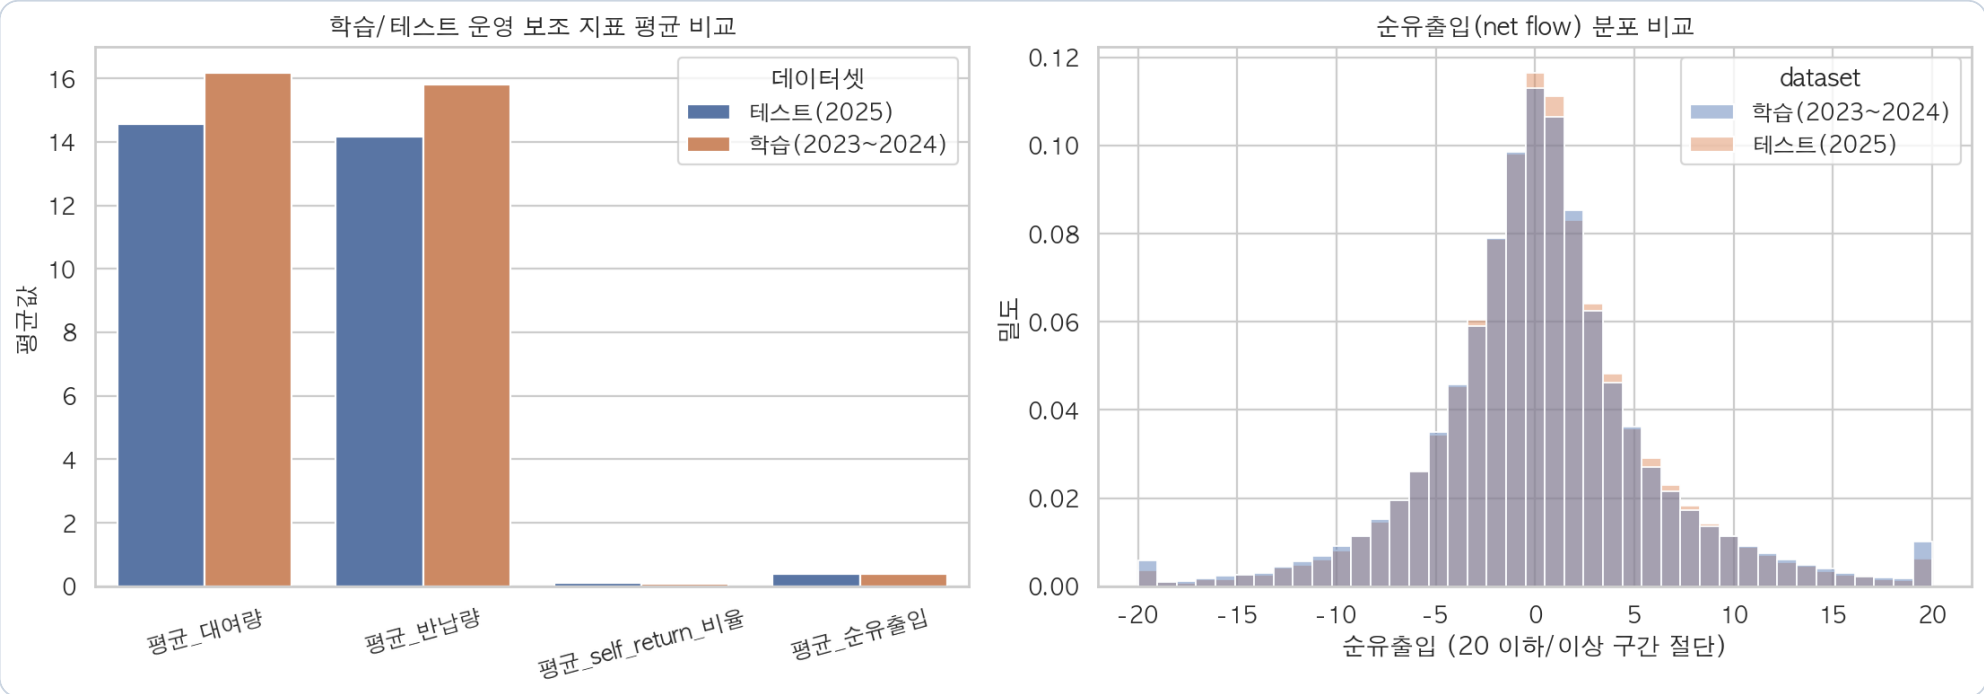

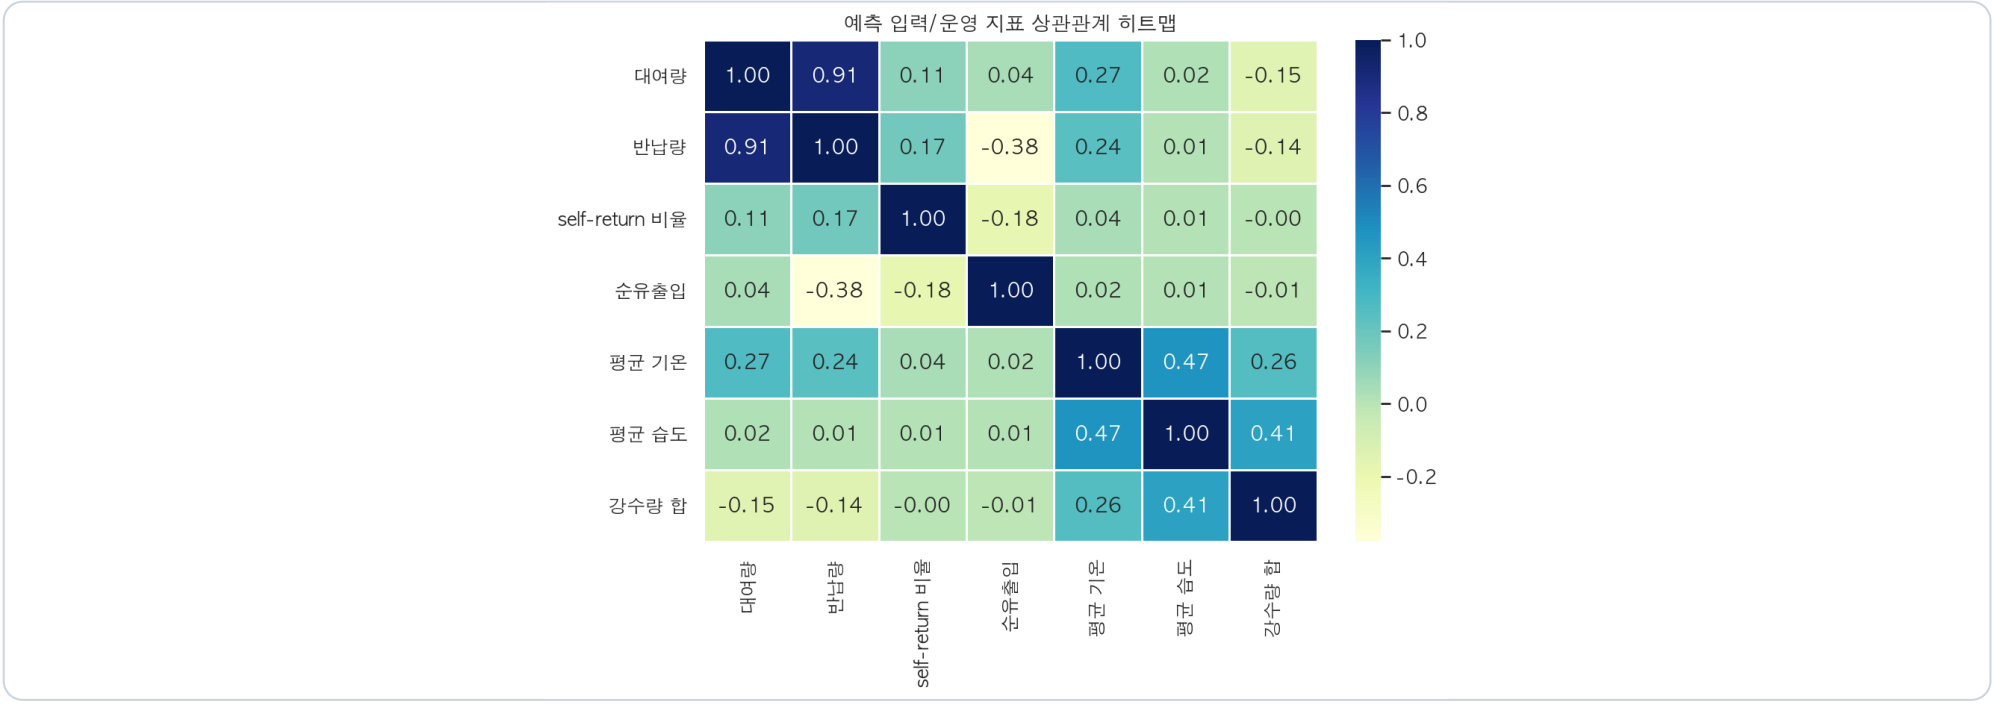

보류 항목

- 생활인구
- 대기질
- 상업/업무 POI

> **상업지구·출퇴근형 해석 = POI와 시간대 지표 보강 후 확장**

7. 머신러닝 모델 및 실험 설계

현재 설계 상태

- baseline target/grain 확정
- 학습/테스트 베이스라인 데이터셋 생성 완료
- 신규/소멸 스테이션 처리 원칙 확정

확정 원칙

- 기존 운영 스테이션: 메인 모델 대상
- 신규 스테이션: cold-start 예외 집합 분리
- 소멸 스테이션: 테스트 제외 또는 운영 이슈 기록

다음 실험 단계

- Linear Regression baseline
- Random Forest
- XGBoost
- LightGBM

> **현재 상태 = 모델 학습 직전, 메인 평가셋과 예외 처리 원칙 확정**

8. 평가 지표

기준 지표

- NMAE

평가 설계 방향

- 메인 평가셋은 기존 운영 스테이션 기준
- 신규 스테이션은 별도 예외 목록으로 분리
- 동일 기준으로 모델별 성능 비교 예정

현재 준비 상태

- 메인 테스트 평가셋 생성 완료
- 예외 스테이션 목록 분리 완료

9. 시스템 구조

캔버스 기준 구조

1. 데이터 수집
2. 데이터 전처리
3. EDA 분석
4. Feature Engineering
5. 모델 학습
6. 예측 생성
7. API 제공
8. 웹 시각화

현재 완료 범위

- 데이터 수집
- 데이터 전처리
- 1차 EDA
- 군집화 및 환경 해석
- 예측용 베이스라인 데이터셋 구축

이후 범위

- 모델 학습 및 평가
- API 명세 구체화

- Flutter 웹 시각화 연결

10. 웹 시스템 구성

목표 기능

- Station 선택
- 날짜 입력
- 예측 대여량 조회
- 지도 기반 시각화

현재 준비된 선행 결과

- Folium 기반 군집 지도 HTML 생성 완료
- 발표용 정적 지도 및 지도 캡처 정리 완료
- 예측 결과를 지도에 연결할 수 있는 데이터 구조 정의 완료

향후 구현 방향

- `/predict` 형태 API 설계
- station-day 입력 기반 결과 반환
- Flutter 지도 위 예측값 표현

11. 프로젝트 일정

기간	캔버스 계획	현재 상태
3.11 ~ 3.12	데이터 구조 확인 및 수집	완료
3.13 ~ 3.14	EDA 및 Feature Engineering	진행 중
3.15 ~ 3.16	모델 개선 및 중간 발표 준비	예정
3.18 ~ 3.20	최종 모델 구축 및 웹 구현	예정
3.21 ~ 3.22	보고서 작성 및 영상 제작	예정
3.23	최종 제출	예정

오늘 기준 정리

- 군집화 발표 자료: 완료
- 예측용 베이스라인 데이터셋: 완료
- 모델 학습: 다음 단계

12. 최종 산출물

캔버스 기준 산출물

- 분석 및 ML 보고서
- 시스템 설계 문서
- 웹 프로젝트
- 시연 영상

현재까지 확보한 중간 산출물

- 군집화 노트북 및 스크립트
- 공휴일/날씨 수집 노트북
- 예측용 베이스라인 데이터셋
- 군집화 발표용 차트, 지도, 발표 문서

13. 기대 결과 및 현재 중간 결론

현재까지 확인한 결과

- 강남구 대여소는 1차 군집화에서 일반수요형과 고수요형으로 구조화됨
- 고수요형은 지하철·버스 접근성이 상대적으로 더 우수함
- 예측용 station-day 베이스라인 데이터셋까지 구축 완료

현재 단계의 의미

- 예측 문제 정의, 데이터셋 구조, 전처리 원칙이 확정됨
- 군집 label과 환경 feature를 예측 모델에 연결할 준비가 끝남
- 이후 단계는 모델 성능 비교와 웹 연결 구현에 집중 가능

> **현재 상태 = 분석 기준 확정 + 예측용 데이터 기반 구축 완료**

부록. 군집화 핵심 결과

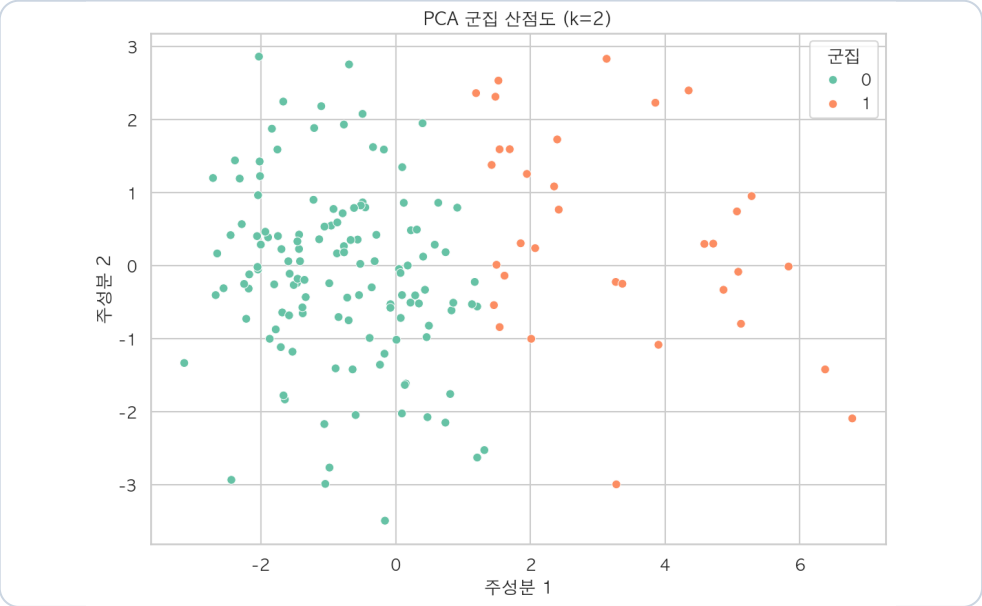

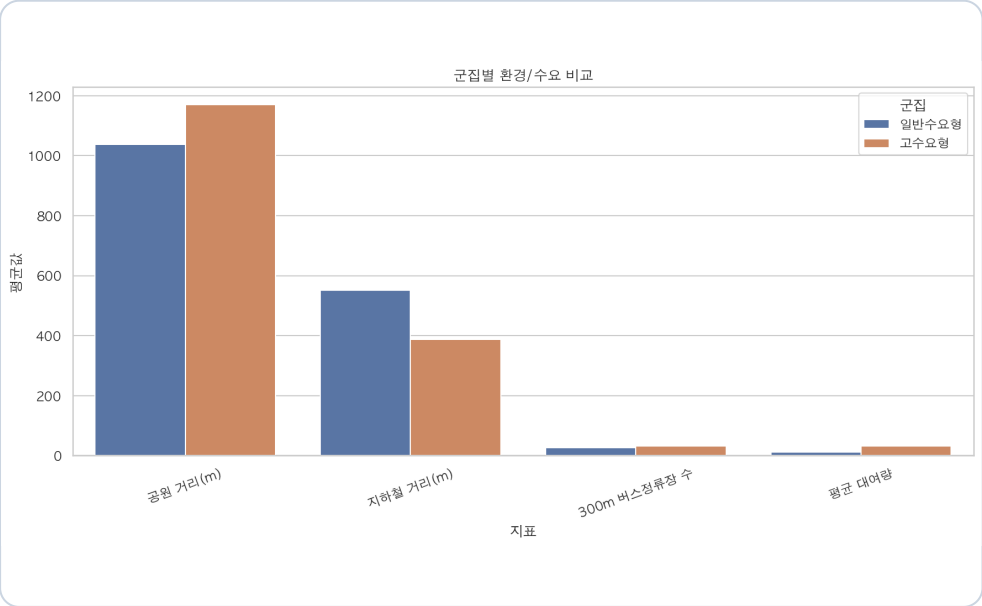

- `k = 2` 기준으로 일반수요형과 고수요형을 도출
- 고수요형은 교통 접근성이 상대적으로 더 좋은 대여소군으로 해석
- 상업지구·출퇴근형 해석은 추가 POI 보강 후 확장 예정